

I. Query 1 – Conteo de Filas por Tabla

Se contó el total de registros en cada tabla mediante UNION ALL para obtener una vista consolidada del volumen de datos disponible.

Tabla	Total de Filas
REAL	505
PRESUPUESTO	95
CATALOGO_AREAS	8

II. Query 2 – Nulos por Columna (Tabla REAL)

Se utilizó la expresión COUNT(*) - COUNT(columna) para identificar registros con valores nulos en cada columna de la tabla REAL. Los nulos detectados representan datos faltantes que deberán ser tratados en el Entregable 5.

Columna (REAL)	Nulos	% del Total	Acción E5
ID_Gasto	0	0.0%	Sin acción
Fecha	0	0.0%	Sin acción
ID_Area	0	0.0%	Sin acción
Area	0	0.0%	Sin acción
Centro_Costo	57	11.3%	Limpiar en E5
Tipo_Gasto	37	7.3%	Limpiar en E5
Proveedor	0	0.0%	Sin acción
Importe	0	0.0%	Sin acción

Hallazgos:

- 57 registros no tienen centro de costo asignado, lo que representa el 11.3% de la tabla. Sin este dato no se puede clasificar correctamente el gasto por unidad organizacional.
- Tipo_Gasto — 37 registros (7.3%) no tienen categoría de gasto. Esto afecta cualquier análisis de distribución de gasto por tipo.
- 117 registros (23.2%) no tienen aprobador registrado. Es el hallazgo más crítico desde el punto de vista de control interno, porque casi 1 de cada 4 gastos no tiene trazabilidad de quién lo autorizó.

III. Query 3 – Estadísticas Descriptivas de Importe

La columna Importe está almacenada como VARCHAR con caracteres '\$' y comas. Para calcular estadísticas sin modificar la tabla original, se aplicó limpieza en memoria con REPLACE() y TRY_TO_DOUBLE(). Esta transformación es temporal; la conversión definitiva se realizará en E5.

Estadística	Valor (MXN)
-------------	-------------

Total registros analizados	505
Importe mínimo (MIN)	\$1,268.02
Importe máximo (MAX)	\$249,159.55
Importe promedio (AVG)	\$119,198.42
Desviación estándar (STDDEV)	\$72,164.15
Mediana (PERCENTILE_CONT 0.5)	\$116,507.72
Importes negativos	0

Hallazgos:

- La columna Importe no es numérica; contiene el símbolo \$ y comas de miles (ejemplo: \$185,296.60). Esto impide hacer sumas, promedios o comparaciones directamente. Para el profiling se limpió en memoria usando REPLACE() + TRY_TO_DOUBLE(), pero eso es solo temporal. En E5 se convertirá definitivamente a tipo FLOAT con ALTER TABLE + UPDATE.

IV. Query 4A – Distribución por Trimestre

El dataset no incluye columna TRIMESTRE explícita. Se calculó dinámicamente usando QUARTER() sobre el resultado de TO_DATE(), con un CASE para manejar los dos formatos de fecha presentes en la columna Fecha.

Trimestre	Registros	% del Total
Trimestre 1	108	21.4%
Trimestre 2	109	21.6%
Trimestre 3	104	20.6%
Trimestre 4	131	25.9%
NULL — sin asignar	53	10.5%

Hallazgos:

- Inconsistencia de formato en Fecha: 53 registros (10.5%) tienen la fecha en formato DD/Mon/YYYY (ejemplo: 23/Nov/2024), mientras que el resto usa YYYY-MM-DD (ejemplo: 2024-02-17). Snowflake no puede parsear ambos formatos al mismo tiempo con un solo TO_DATE(), por lo que esos 53 registros quedan sin trimestre asignable y aparecen como NULL en la distribución.

V. Query 4B – Rango de Fecha

Se calculó la fecha más antigua (MIN), la más reciente (MAX) y la cobertura total en días (DATEDIFF), aplicando el mismo CASE de doble formato de la Query 4A.

Métrica	Valor
Fecha mínima (MIN)	02/01/2024
Fecha máxima (MAX)	31/12/2024
Días de cobertura (DATEDIFF)	364 días

VI. Query 5A — Valores Distintos en Tabla REAL

Se contó el número de valores únicos en las columnas categóricas clave de REAL para evaluar la diversidad y consistencia de los datos.

Dimensión (REAL)	Valores Distintos
Áreas distintas (ID_Area)	8
Tipos de gasto (Tipo_Gasto)	8
Proveedores distintos (Proveedor)	11
Aprobadores distintos (Aprobado_Por)	7 (excluye NULLs)

Tipos de gasto identificados (8 categorías):

#	Tipo de Gasto Único
1	Capacitación
2	Equipo
3	Mantenimiento
4	Materiales
5	Nómina
6	Servicios Externos
7	Utilities
8	Viáticos

Los 11 proveedores y 7 aprobadores reflejan una operación con proveedores diversificados y un grupo reducido de autorizadores, lo cual es típico en finanzas corporativas.

VII. Query 5B — Estructura y Distribución de Tabla PRESUPUESTO

Se analizó la cobertura y distribución de PRESUPUESTO para validar que todas las áreas estén presupuestadas en todos los meses y que la moneda sea consistente.

Dimensión (PRESUPUESTO)	Distintos	Observación
Áreas distintas (ID_Area)	8	Todas las áreas cubiertas
Meses distintos (Mes)	12	Cobertura anual completa
Monedas distintas (Moneda)	1	Solo MXN

Mes	Num_Mes	Registros	Áreas	Presupuesto Total MXN
Enero	1	8	8	\$12,383,172.23
Febrero	2	8	8	\$12,806,498.71
Marzo	3	8	8	\$11,923,210.71
Abril	4	8	8	\$11,424,487.98
Mayo	5	8	8	\$11,854,176.91
Junio	6	8	8	\$11,760,444.32
Julio	7	8	8	\$12,164,311.67
Agosto	8	8	8	\$11,257,218.92
Septiembre	9	8	8	\$11,597,844.94
Octubre	10	8	8	\$12,044,900.38
Noviembre	11	8	8	\$11,803,330.03
Diciembre	12	8	8	\$12,189,106.84
TOTAL ANUAL		96	8	\$143,208,703.64

El presupuesto mensual oscila entre \$11.3M (Agosto) y \$12.8M (Febrero) MXN, con un total anual de \$143,208,703.64 MXN.

VIII. Conclusiones y Plan de Limpieza

El proceso de Data Profiling reveló que el dataset tiene una cobertura temporal adecuada (364 días del 2024) y una estructura de presupuesto completa (8 áreas x 12 meses). Sin embargo, se identificaron problemas de calidad que deben resolverse en E5:

- Centro_Costo (57 nulos, 11.3%)
- Aprobado_Por (117 nulos, 23.2%)
- Tipo_Gasto (37 nulos, 7.3%)
- Fecha (53 registros con formato mixto)
- Importe (VARCHAR con \$ y comas)

Al terminar E5 se re-ejecutarán las queries de profiling para confirmar que todos los hallazgos quedaron resueltos antes de proceder con los JOINS del Entregable 6.